

ĐẠI HỌC QUỐC GIA TP.HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN

XỬ LÝ NGÔN NGỮ TỰ NHIÊN
CS221.Q21

ĐỀ TÀI

Food Order Extraction
Annotation Guidelines

GVHD: TS. Nguyễn Trọng Chính

Sinh viên thực hiện:

Võ Thành Lộc

24520989

Nguyễn Anh Nguyên

24521185

Ngày 3 tháng 7 năm 2026

Mục lục

1	Bối cảnh và tác vụ	2
2	Hệ thống nhãn và quy tắc gán nhãn	2
2.1	Hệ thống nhãn	2
2.2	Quy tắc gán nhãn	3
3	Xử lý ngoại lệ	3
4	Kiểm soát chất lượng	3
4.1	Quy trình gán nhãn độc lập và kiểm tra chéo	3
4.2	Thảo luận và giải quyết xung đột	3
4.3	Đo lường độ đồng thuận	4
4.4	Đánh giá chất lượng tập dữ liệu	4

1 Bối cảnh và tác vụ

Bối cảnh: Dữ liệu đầu vào được thu thập từ các bình luận, tin nhắn đặt hàng thực tế của quán cơm chay Diệu Thiện trên nền tảng mạng xã hội Facebook. Đặc thù của loại dữ liệu này là phi cấu trúc, chứa nhiều nhiễu, từ lóng, teencode, viết tắt và các địa danh đặc thù.

Tác vụ: Dữ liệu dành cho bài toán Nhận diện thực thể (Named Entity Recognition - NER). Người gán nhãn có nhiệm vụ đọc hiểu ngữ cảnh của câu, xác định chính xác ranh giới các cụm từ mang thông tin cốt lõi của đơn hàng và phân loại chúng vào các nhãn đã được quy định sẵn.

2 Hệ thống nhãn và quy tắc gán nhãn

2.1 Hệ thống nhãn

Nhóm định nghĩa 7 thực thể cốt lõi cần trích xuất bao gồm:

- **QUANTITY:**

- *Định nghĩa:* Số lượng phần ăn.
- *Ví dụ:* 1, 1p, 1 phần, một, 1ph...
- *Lưu ý:* Nếu có đơn vị đi kèm (phần, hộp,...), nhãn bao trọn cả số và đơn vị.

- **FOOD:**

- *Định nghĩa:* Tên món ăn, gia vị và nước sốt.
- *Ví dụ:* Cơm, đậu hũ, canh, ớt, nước tương,...
- *Lưu ý:* Chia ranh giới theo từng món trong menu. Minh họa: rau muống cá viên → rau muống (FOOD), cá viên (FOOD).

- **NOTE:**

- *Định nghĩa:* Các yêu cầu về khẩu vị, định lượng.
- *Ví dụ:* ít/nhiều, thêm/bớt, không, ko, riêng,...
- *Lưu ý:* Tách biệt với nguyên liệu. Minh họa: cơm thêm → cơm (FOOD), thêm (NOTE).

- **PLACE:**

- *Định nghĩa:* Địa điểm giao nhận hàng, giới từ chỉ vị trí tương đối.
- *Ví dụ:* rào AH, cổng chính, khu A, đối diện, gần, kế bên...
- *Lưu ý:* Gán nhãn độc lập cho từng khối địa điểm/vị trí nhỏ nhất có thể. Minh họa: đối diện cổng chính UIT → đối diện (PLACE), cổng chính (PLACE), UIT (PLACE).

- **PHONE:**

- *Định nghĩa:* Số điện thoại.
- *Ví dụ:* 4423456789, ...
- Đã được mã hóa bằng thuật toán Format-Preserving Encryption (FPE) nhằm giữ nguyên định dạng nhưng vẫn bảo mật quyền riêng tư. Cụ thể là ánh xạ từng chữ số sang 1 chữ số khác. Đặc biệt với 2 chữ số đầu tiên, thay thế bằng tổng các chữ số phía sau, nhằm tạo đầu số giả đảm bảo không ảnh hưởng người khác.

- **TIME:**

- *Định nghĩa:* Thời gian nhận hàng.
- *Ví dụ:* 18h, 5:00, sớm, liền, đợt 1, sớm nhất, trước 5h40...
- *Lưu ý:* Có thể là thời gian cụ thể hoặc từng mốc thời gian cho người bán quy định (đợt 1, đợt 2...) hoặc độ ưu tiên khi giao (sớm, liền, ...).

- **PRICE:**

- *Định nghĩa:* Giá tiền của phần ăn và đơn vị tiền tệ.

- Ví dụ: 15, 20k, 17 nghìn, ...
- Lưu ý: Nếu con số đi kèm với đơn vị tiền tệ (k, ngàn, đ, vnd) bị viết tách rời bởi khoảng trắng, nhãn phải bao trọn cả số và đơn vị.

2.2 Quy tắc gán nhãn

- Khi gán nhãn thực thể chứa nhiều âm tiết, bắt buộc phải bao trùm toàn bộ khoảng trắng giữa các âm tiết đó.
- Không gộp các dấu câu (" ", ". ", ...) và toán tử (" + ", " ", ...) vào trong thực thể, trừ khi thuộc tên riêng.
- Ngầm định các từ ghép trong tiếng Việt (VD: rau muống, bắp cải) là khối ngữ nghĩa hoàn chỉnh, tuyệt đối không chia ranh giới ở giữa cụm từ này.
- Không tự ý sửa lỗi chính tả hay teencode, gán nhãn đúng ý nghĩa của câu gốc (VD: xx (~ xúc xích) → xx (FOOD)).

3 Xử lý ngoại lệ

- Trường hợp dính liền số và chữ hoặc chữ và chữ, phải tách chính xác ranh giới nhãn. (VD: rau muống+cá viên → rau muống (FOOD), cá viên (FOOD)). Nếu dính chữ quá phức tạp không thể tách, đánh dấu là mẫu dữ liệu lỗi.
- Bỏ qua các ghi chú về phương thức giao dịch (mặc định do cửa hàng tự xử lý thủ công).
- Chấp nhận các mẫu dữ liệu thiếu thành phần (không có PHONE, PLACE, ...). Thực hiện gán nhãn bình thường trên các thực thể đang hiện diện.
- Không sử dụng số đếm (1, 2, 3) mà dùng danh từ chỉ vật chứa hoặc từ ước lượng để đại diện cho số lượng (VD: cho hộp cơm chay (lấy nửa cơm) → hộp (QUANTITY), nửa (QUANTITY)).

4 Kiểm soát chất lượng

Nhóm đã thiết lập một quy trình kiểm định nghiêm ngặt nhiều lớp nhằm giảm thiểu tối đa yếu tố chủ quan của con người.

4.1 Quy trình gán nhãn độc lập và kiểm tra chéo

Toàn bộ 2325 mẫu dữ liệu được phân phối cho các thành viên để gán nhãn độc lập. Bước đầu, nhóm tiến hành trên tập mẫu thử (pilot) 50 câu. Quá trình kiểm định chia làm 2 giai đoạn:

- **Tự kiểm tra:** Người gán nhãn rà soát kết quả của mình dựa trên bộ quy tắc đã thống nhất để loại bỏ các lỗi cơ bản như: thiếu nhãn, gộp nhầm các thực thể hoặc gán nhầm nhãn.
- **Đối chiếu chéo:** Dữ liệu được hoán đổi giữa các thành viên. Bất kỳ sự bất đồng nào trong việc xác định ranh giới từ hoặc loại thực thể đều được ghi nhận lại vào một biên bản đánh giá chung để đảm bảo tính nhất quán cho toàn bộ quy trình.

4.2 Thảo luận và giải quyết xung đột

Các xung đột phổ biến thường tập trung vào hai vấn đề:

- Sự chênh lệch trong việc xác định độ dài ranh giới của cụm từ chỉ địa điểm (PLACE).
- Sự nhầm lẫn giữa nguyên liệu/món ăn (FOOD) và các yêu cầu lồng ghép (NOTE).

Với các trường hợp này, nhóm tiến hành thảo luận phân tích lại ngữ cảnh câu. Mọi quyết định cuối cùng đều phải dựa trên nguyên tắc chia nhỏ thực thể hoặc các luật xử lý ngoại lệ đã đề ra. Các điểm bất đồng này sau đó tiếp tục được cập nhật vào bộ quy tắc chung để làm tiền lệ cho các mẫu dữ liệu sau.

4.3 Đo lường độ đồng thuận

Thước đo quan trọng nhất để khẳng định tính khách quan và độ "sạch" của bộ dữ liệu là tỷ lệ đồng thuận. Một nhãn gán chỉ được tính là đồng thuận khi khớp hoàn toàn ở mức độ thực thể (Ví dụ: B-FOOD, I-FOOD) lẫn độ dài ranh giới ký tự.

Sau khi trải qua các vòng đối chiếu chéo và giải quyết triệt để các xung đột, nhóm tiến hành tính toán độ đồng thuận trên toàn bộ tập dữ liệu. Do dữ liệu bài toán NER của nhóm có sự mất cân bằng nhãn lớn (nhãn FOOD và O chiếm đa số). Nhóm chọn hệ số Gwet's AC1 thay cho Cohen's Kappa truyền thống nhằm tránh 'Nghịch lý Kappa'. Gwet's AC1 cung cấp cơ chế loại trừ yếu tố đồng thuận ngẫu nhiên ổn định hơn, phản ánh chính xác chất lượng dữ liệu:

$$AC_1 = \frac{P_a - P_e}{1 - P_e} \quad (1)$$

Với:

- AC_1 (Agreement Coefficient 1): Độ đồng thuận Gwet's AC1.
- P_a (Observed agreement): Tỷ lệ đồng thuận thực tế giữa 2 người gán nhãn.
- P_e (Chance Agreement): Xác suất đồng thuận ngẫu nhiên đã được hiệu chỉnh theo thuật toán Gwet.

4.4 Đánh giá chất lượng tập dữ liệu

Thực nghiệm đo lường trên toàn bộ tập dữ liệu ghi nhận chỉ số đồng thuận AC_1 đạt 98,87%. Con số xuất sắc này khẳng định bộ quy tắc gán nhãn do nhóm xây dựng có tính logic chặt chẽ, loại bỏ sự cảm tính cá nhân và kiểm soát tỷ lệ nhãn nhiễu ở mức rất thấp.